



# Nghiên cứu và phát triển giải pháp hỗ trợ người dùng dựa trên Mô hình Ngôn ngữ lớn trên các hệ thống Tính toán Hiệu năng cao (HPC-GPT)


## GIỚI THIỆU ĐỀ TÀI

Sự ra đời của lĩnh vực **Tính toán Hiệu năng cao (HPC)** và các **hệ thống HPC** đã mở ra cơ hội hỗ trợ phát triển các ngành khoa học, công nghệ yêu cầu nhiều **tài nguyên tính toán** và xử lý **khối lượng dữ liệu lớn** như Vật lý, Sinh học, Thiên văn học, ... Một lĩnh vực khác cũng đang được quan tâm là các **Mô hình Ngôn ngữ lớn (LLM)**, cụ thể là có ngày càng nhiều các LLM ra đời với nhiều đặc điểm và thế mạnh khác nhau.

Vận dụng các yếu tố trên, đề tài hướng đến xây dựng một **chatbot** trên website nhằm hỗ trợ người dùng **sử dụng các hệ thống HPC**.

Đề tài sẽ **đóng góp** vào sự phát triển của các **lĩnh vực LLM**, **chatbot hỗ trợ người dùng** trên lĩnh vực **HPC**, từ đó góp phần thúc đẩy các ngành khoa học có liên quan.

Sơ đồ kiến trúc chung của hệ thống



## MỤC TIÊU ĐỀ TÀI

Đề tài hướng đến phát triển một **chatbot** có kiến thức về **lĩnh vực** và **hệ thống HPC**, đồng thời được **kết nối với một hệ thống HPC** để có thể đưa ra những câu trả lời **chính xác** và được cập nhật **theo thời gian thực**.

## KIẾN TRÚC HỆ THỐNG



Hệ thống gồm các thành phần chính:

- Giao diện người dùng
- Máy chủ chính để xử lý hầu hết các logic và tương tác với giao diện người dùng.
- Máy chủ RAG xử lý prompt và đưa ra câu trả lời cho người dùng
- Cơ sở dữ liệu MongoDB chứa các dữ liệu chính của ứng dụng như cuộc trò chuyện, tin nhắn hay thông tin người dùng.
- Hệ thống HPC được kết nối vào ứng dụng, cung cấp cho chatbot khả năng trả lời với những dữ liệu chính xác và được cập nhật theo thời gian thực.
- Các API bên ngoài như vị trí, Wikipedia, thời tiết, ...

## ĐÁNH GIÁ RAGAS

| Input Query | Contextual Precision | Contextual Recall | Faithfulness | Answer Relevancy | RAGAS Score |
|-------------|----------------------|-------------------|--------------|------------------|-------------|
| 1           | 1.0000               | 1.0000            | 0.6000       | 0.7695           | 0.8424      |
| 2           | 1.0000               | 0.0000            | 1.0000       | 0.9602           | 0.7400      |
| 3           | 0.0000               | 0.0000            | 1.0000       | 0.9645           | 0.4911      |
| 4           | 1.0000               | 1.0000            | 1.0000       | 0.7342           | 0.9335      |
| 5           | 1.0000               | 1.0000            | 0.6667       | 0.9352           | 0.9005      |
| 6           | 0.0000               | 0.0000            | 1.0000       | 0.7455           | 0.4364      |
| 7           | 0.0000               | 1.0000            | 1.0000       | 0.7533           | 0.6883      |
| 8           | 1.0000               | 0.0000            | 1.0000       | 0.8962           | 0.7241      |
| 9           | 1.0000               | 0.0000            | 0.5000       | 0.8657           | 0.5914      |
| 10          | 0.5000               | 0.0000            | 1.0000       | 0.9651           | 0.6163      |
| 11          | 0.3333               | 0.0000            | 0.8000       | 0.8833           | 0.5042      |
| 12          | 1.0000               | 0.0000            | 0.6000       | 0.9823           | 0.6456      |
| 13 (Failed) | 0.0000               | 0.0000            | 0.0000       | 0.0000           | 0.0000      |
| 14          | 0.0000               | 1.0000            | 1.0000       | 0.7515           | 0.6879      |
| 15          | 1.0000               | 0.0000            | 1.0000       | 0.9970           | 0.7493      |
| Mean        | 0.5889               | 0.3333            | 0.8690       | 0.8136           |             |

Đánh giá trên 15 câu hỏi đầu tiên liên quan tới HPC Lab được sinh bởi GPT-4o.



## NHỮNG GÌ NHÓM ĐÃ HIỆN THỰC

- Tích hợp dữ liệu cập nhật liên tục thông qua các API.
- Áp dụng Sentence Window, Cohere Re-ranking và HyDE để đảm bảo kết quả chính xác và trung thực (tập trung cải thiện quá trình retrieval - pre-retrieval & post-retrieval).
- Triển khai kỹ thuật ReAct, cho phép lý luận và sử dụng hợp lý các kết nối với nguồn dữ liệu, công cụ truy vấn và khả năng gọi hàm của các LLM.
- Đánh giá query engine dựa trên các thông số RAGAS.
- Xây dựng giao diện và các máy chủ cho ứng dụng và tích hợp mô hình LLM đã phát triển vào ứng dụng.
- Triển khai hệ thống lên nền tảng HPC Lab để sử dụng rộng rãi.

## TÀI LIỆU THAM KHẢO

- Shunyu Yao et al. **"ReAct: Synergizing Reasoning and Acting in Language Models"**. In: arXiv preprint arXiv:2210.03629 (2022)
- Peitian Zhang et al. **"Retrieve Anything To Augment Large Language Models"**. arXiv: 2310.07554 [cs.IR] (2023)
- Luyu Gao et al. **"Precise Zero-Shot Dense Retrieval without Relevance Labels"**. arXiv: 2212.10496 [cs.IR] (2022)
- Jerry Liu. **"LlamaIndex"**. (Nov. 2022). doi: 10.5281/zenodo.1234. URL: [https://github.com/jerryliu/llama\\_index](https://github.com/jerryliu/llama_index).
- Shahul Es et al. **"RAGAS: Automated Evaluation of Retrieval Augmented Generation"**. arXiv: 2309.15217 [cs.IR] (2023)

## KẾT LUẬN

### Thành quả đạt được:

- Một trợ lý có quyền truy cập vào nhiều công cụ kết nối với các nguồn dữ liệu cần thiết của HPC Lab và dữ liệu từ Internet.
- Một trợ lý có khả năng tương tác với hệ thống thông qua function calling.

### Những điều cần cải thiện:

- Thời gian phản hồi chưa được tối ưu.
- Hallucinations vẫn còn xuất hiện khi sử dụng mô hình Mixtral
- Còn phụ thuộc vào một số mô hình trả phí của Cohere cho quá trình embeddings, re-ranking.

### Định hướng tương lai của đề tài

- Kết hợp thêm một số kỹ thuật xử lý pre/post-retrieval.
- Nghiên cứu về kiến trúc Modular RAG