



TRƯỜNG ĐẠI HỌC BÁCH KHOA - ĐHQG-HCM


KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH

Tên nhóm: **Sử dụng mô hình ngôn ngữ lớn để giải quyết câu hỏi trắc nghiệm**

SV: Đặng Phú Quốc | MSSV: 2014294

BÁO CÁO LUẬN VĂN TỐT NGHIỆP

GVHD: PGS.TS Quản Thành Thơ



Giới thiệu đề tài

Hiện nay, sự bùng nổ của các mô hình ngôn ngữ lớn (LLM) đã đạt được những tiến bộ vượt bậc trong xử lý ngôn ngữ tự nhiên (NLP). Song với đó, các tập dữ liệu cũng được phát triển để đánh giá mô hình, đặc biệt là tác vụ câu hỏi trắc nghiệm.

Nghiên cứu này tập trung vào việc cải thiện khả năng trả lời câu hỏi trắc nghiệm (MCQ) của các mô hình ngôn ngữ lớn.

Đặc tả yêu cầu / Thách thức

Yêu cầu: Nghiên cứu các phương pháp để cải thiện khả năng trả lời trắc nghiệm của mô hình.

Thách thức:

• LLM phụ thuộc vào nhãn ("A", "B", "C", ...) và khả năng liên kết ký hiệu của mô hình (Symbol Binding Ability) để trả lời câu hỏi trắc nghiệm.

• Cần nghiên cứu phương pháp tối ưu để có thể khai thác triệt để hơn khả năng của mô hình ngôn ngữ lớn.

Phương pháp nghiên cứu

Nhóm đề xuất hai phương pháp để cải thiện khả năng trả lời của mô hình.

1. Single Token Logits Approach:

Một cách tiếp cận cho tác vụ mà không cần dùng đến các giá trị logit đầu ra của các token nhãn ("A", "B", "C", "D",...) như phương pháp cơ sở. Thay vào đó, chỉ sử dụng giá trị logit đầu ra của một loại token duy nhất, trong trường hợp áp dụng hiện tại là token "yes".

Cụ thể, đối với mỗi câu hỏi có k lựa chọn, chuyển chúng thành k prompt tương ứng, gồm câu hỏi và một lựa chọn trả lời. Xét ở giá trị đầu ra của LLM cho token vị trí đầu tiên, giá trị logit của token "yes" được sử dụng để đại diện cho mức độ đồng ý của mô hình với từng lựa chọn. Kết quả logit của các prompt được so sánh và chuẩn hóa bằng hàm softmax để xác định xác suất các lựa chọn. Công thức được định nghĩa như sau:

$$P(a_i|q) = \frac{\exp(l_{yes}(q, a_i))}{\sum_{j \in k} \exp(l_{yes}(q, a_j))}$$

Trong đó:

q : Nội dung câu hỏi
 a_i : Một câu trả lời i trong năm trong tập các lựa chọn
 l_{yes} : Giá trị logit đầu ra của token "yes" (xét ở token đầu tiên được sinh ra)
 $P(a_i|q)$: Xác suất dự đoán của của câu trả lời a_i

2. Enhanced-query RAG:

Nhóm nghiên cứu đã áp dụng kỹ thuật RAG nhằm truy xuất thông tin bên ngoài để bổ sung vào câu hỏi. Nhóm sử dụng cơ sở dữ liệu vector và tìm kiếm tương đồng (similarity search) để tìm thông tin liên quan. Một số thông tin cụ thể về việc tổ chức hệ thống.

Nguồn tài liệu: Sử dụng tập dữ liệu từ Wikipedia tiếng Anh với khoảng 6.5 triệu bài viết.


Mô hình nhúng văn bản: Chuyển đổi dữ liệu văn bản thành các vector để so sánh và tính toán. Nhóm sử dụng mô hình nhúng kiểu BERT *bge-small-en*, nổi bật với độ chính xác cao và kích thước vector nhúng tối ưu (128).

Tổ chức cơ sở dữ liệu vector: Cách tổ chức tương đồng với RAG, mỗi bài viết được chia thành các phần nhỏ (*chunk*) và biểu diễn bằng vector nhúng. Khi có câu truy vấn, hệ thống tìm kiếm trong chỉ mục và trả về các kết quả liên quan nhất, sử dụng thông tin được truy xuất đó để bổ sung vào câu hỏi.


Điểm khác biệt của cách tổ chức so với RAG nằm ở cải tiến truy vấn. Bằng việc sử dụng LLM để sinh ra các kiến thức liên quan (*knowledge facts*) từ câu hỏi, sau đó sử dụng chúng để làm câu truy vấn cho hệ thống thay vì câu hỏi như thông thường, từ đó tìm kiếm trong cơ sở dữ liệu vector.

Kiến trúc hệ thống

Single Token Logits Approach



Enhanced-query RAG



Kết quả thực hiện

Hai bảng dưới đây trình bày kết quả thực nghiệm (*accuracy metric %*).

Bảng đầu tiên thống kê kết quả cụ thể trên các dataset của từng kiểu tiếp cận với từng hệ thống truy xuất ngữ cảnh khác nhau.

Bảng thứ hai tổng hợp kết quả trên toàn bộ tập dữ liệu **ARC**, thể hiện tương quan kết hợp giữa cách tiếp cận LLM và các trường hợp hệ thống ngữ cảnh bổ sung. Trong đó:

Cột: Đại diện cho cách tiếp cận LLM, với cột đầu tiên là phương pháp cơ sở (LTL) và cột thứ hai là phương pháp đề xuất (STL).

Hàng:

- Hàng đầu tiên: Không có ngữ cảnh bổ sung.
- Hàng thứ hai: Ngữ cảnh từ kỹ thuật RAG thông thường.
- Hàng thứ ba: Ngữ cảnh từ kỹ thuật RAG với cải thiện query.

Nhận xét:

- Phương pháp tiếp cận đề xuất luôn có độ chính xác cao hơn so với cơ sở trong cùng điều kiện ngữ cảnh.
- Xét trên cùng một cột ở bảng 2, độ chính xác tăng dần từ "Empty" < "RAG" < "Enhanced query RAG".
- Số liệu gốc của mô hình Mistral 7B là **71.9%** trên tập dữ liệu ARC, không sử dụng ngữ cảnh bổ sung.
- Lưu ý, tất cả các thí nghiệm đều sử dụng zero-shot prompting để đánh giá hiệu quả của các phương pháp cải thiện.

Mistral 7B	Context	ARC Easy	ARC Challenge	ARC (Summary)
Original Paper		80.0	55.5	71.9
LTL	Empty	75.55	63.99	71.7
STL		84.34	67.15	78.66
LTL	RAG	81.19	66.89	76.46
STL		85.69	67.24	79.59
LTL	Enhance query RAG	84.55	70.05	79.76
STL		89.10	72.18	83.51

	Approach	LTL	STL
Context	No Context	71.7	78.66
	RAG	76.46	79.59
	Enhance Query RAG	79.76	83.51

Kết luận

Nghiên cứu đã cải thiện khả năng trả lời câu hỏi trắc nghiệm của mô hình ngôn ngữ lớn (LLM). Các kết quả cho thấy các phương pháp đề xuất tốt hơn so với phương pháp cơ sở và duy trì độ ổn định khi kết hợp với nhau. Một số kết luận chính từ thực nghiệm:

• Sử dụng giá trị logit của token duy nhất: Việc dùng giá trị logit của một loại token duy nhất (như "yes") thay vì các nhãn (như "A", "B", "C", ...) giúp tận dụng tốt hơn khả năng của LLM, và không bị phụ thuộc vào nhãn để trả lời câu hỏi trắc nghiệm cũng như cải thiện độ chính xác.

• Cải thiện câu truy vấn với hệ thống RAG: Sử dụng kiến thức sinh ra từ LLM để làm câu truy vấn giúp tìm kiếm thông tin chất lượng hơn, hỗ trợ tìm kiếm tương đồng vector và tăng chất lượng thông tin truy xuất. Tùy vào đặc thù của dữ liệu được tổ chức mà có thể tối ưu hóa prompt trong việc yêu cầu LLM sinh ra văn bản để tìm kiếm.

Nghiên cứu hiện tại tập trung vào câu hỏi trắc nghiệm, cần kiểm chứng thêm trên các mô hình khác nhau và cũng như mở rộng nghiên cứu cho các tác vụ khác như sinh văn bản hay câu hỏi toán học phức tạp, mở ra các hướng phát triển nghiên cứu sau này.